

Taller #1 Análisis Predictivo y Aprendizaje Estadístico

Presentado por:

Karent Juliana Espejo Martinez

Brayan Esteban Aponte Baron

Sergio Steban Aguirre Alfonso

Presentado a:

Fredy Orjuela

Sistemas Avanzados de Producción

Ingeniería Industrial

Universidad ECCI

Febrero de 2026

Bogotá D.C

Introducción

En el entorno competitivo de los Sistemas Avanzados de Producción y la Ingeniería Industrial, la toma de decisiones no puede basarse en la intuición, sino en el análisis riguroso de datos. El presente estudio aborda uno de los dilemas financieros más comunes en las organizaciones: la optimización del presupuesto de marketing. A través del conjunto de datos Advertising, se analiza el comportamiento de las ventas en 200 mercados distintos como respuesta a la inversión en tres canales: Televisión (TV), Radio y Periódicos (Newspaper).

El problema central radica en identificar qué combinación de medios de comunicación maximiza el retorno de ventas y si existen canales que, a pesar de recibir inversión, no contribuyen significativamente al éxito comercial. Este análisis es crítico para evitar el desperdicio de recursos y para entender la elasticidad de la demanda frente a los estímulos publicitarios.

Objetivos del Análisis:

1. Caracterizar el comportamiento estadístico de cada variable para detectar sesgos, concentraciones de inversión y posibles valores atípicos que puedan distorsionar las decisiones estratégicas.
2. Evaluación de Asociación: Cuantificar la fuerza de la relación lineal y monótona entre los medios y las ventas mediante los coeficientes de Pearson y Spearman, estableciendo una jerarquía de relevancia entre los canales.
3. Modelamiento Predictivo: Desarrollar un modelo de regresión lineal múltiple para estimar los parámetros que rigen la relación ventas-publicidad, permitiendo predecir escenarios futuros y calcular el volumen de ventas base (orgánicas) de la operación.

Fase 1: Estadística Descriptiva y Análisis Exploratorio

Medidas de Tendencia Central

Las medidas de tendencia central muestran que TV tiene el promedio más alto, lo que indica que es el medio donde, en general, se realiza mayor inversión. La media y la mediana son muy cercanas y su sesgo (-0.07) es casi cero, lo que confirma que los datos están distribuidos de forma equilibrada. Su curtosis negativa (-1.23) indica que los valores están más repartidos y no se concentran fuertemente en un solo rango.

En radio, la media y la mediana son muy similares, lo que evidencia una distribución simétrica y estable; esto se confirma con un sesgo cercano a cero (0.09). Su curtosis negativa (-1.26) muestra que los datos están distribuidos de manera uniforme, sin presencia importante de valores extremos.

En newspaper, la media es mayor que la mediana, lo que indica asimetría positiva, respaldada por un sesgo de 0.89, lo que significa que existen algunas inversiones altas que influyen en el promedio. Su curtosis positiva (0.65) indica mayor concentración de datos en ciertos valores y presencia de algunos extremos.

Variable	Media	Mediana	Desv. Std	Min	Max	Asimetría	Curtosis
TV	147.04	149.75	85.85	0.7	296.4	-0.07	-1.23
Radio	23.26	22.90	14.85	0.0	49.6	0.09	-1.26
Newspaper	30.55	25.75	21.78	0.3	114.0	0.89	0.65
Sales	14.02	12.90	5.22	1.6	27.0	0.41	-0.41

Tabla [1]: En esta tabla se presentan las medidas de tendencia central y dispersión correspondientes a las variables independientes (TV, radio y newspaper) y a la variable dependiente (sales), con el fin de describir el comportamiento general de los datos.

Análisis de Distribución y Atípicos

La Figura 1 evidencia diferencias claras en la variabilidad de las variables. TV presenta la mayor dispersión, lo que indica que la inversión en este medio varía considerablemente entre observaciones; esto se refleja en un rango amplio y una mayor distancia entre los valores mínimos y máximos. En contraste, radio muestra una distribución más concentrada alrededor de su mediana, lo que sugiere menor variabilidad.

Por su parte, newspaper presenta asimetría positiva, lo que implica que existen algunas observaciones con inversión considerablemente mayor al promedio (posibles valores atípicos).




Figura [1]: Se muestra la distribución y dispersión de las variables independientes (TV, radio y newspaper) y la variable dependiente (sales) mediante histogramas y diagramas de caja, permitiendo identificar su comportamiento, variabilidad y posible asimetría.

Evaluación de Asociación:

Pearson:

La matriz de Pearson confirma un patrón similar, pero desde una perspectiva lineal: **TV (0.78)** mantiene una correlación fuerte y positiva con ventas, lo que indica una relación lineal directa importante. **Radio (0.58)** presenta una correlación moderada positiva, mientras que **newspaper (0.23)** tiene una relación débil. Las correlaciones entre las variables independientes son bajas, lo que sugiere poca multicolinealidad. En conjunto, los resultados indican que la inversión en TV es el factor con mayor relación lineal con las ventas.




Figura [2]: La matriz muestra los coeficientes de correlación de Pearson entre las variables analizadas, indicando la fuerza y dirección de la relación lineal entre la inversión en medios y las ventas.

Spearman

La matriz de Spearman muestra que la relación más fuerte con las ventas es la inversión en TV (0.80), indicando una asociación positiva alta: a mayor inversión en TV, mayores ventas en términos monotónicos. La variable radio (0.55) presenta una relación moderada positiva con ventas, mientras que newspaper (0.19) muestra una asociación débil. Entre las variables independientes, las correlaciones son bajas (TV con radio y newspaper casi nulas), lo que sugiere que no existe una dependencia fuerte entre los medios. En general, TV es el medio con mayor asociación con el comportamiento de las ventas.




Figura [3]: La matriz presenta los coeficientes de correlación de Spearman entre las variables de inversión publicitaria y ventas, mostrando la intensidad y dirección de la relación monotónica entre ellas.

¿Qué significa un coeficiente cercano a 1 o -1 en este contexto?

Un coeficiente cercano a 1 indica una relación positiva muy fuerte: cuando aumenta la inversión publicitaria, aumentan las ventas de manera consistente. Si fuera cercano a -1, indicaría una relación negativa muy fuerte: al aumentar la inversión, las ventas disminuirían. En este caso, los valores altos (como TV con ventas ≈ 0.78 – 0.80) indican que mayor inversión en TV se asocia claramente con mayor retorno en ventas.

¿Cómo se interpreta un valor cercano a 0?

Un coeficiente cercano a 0 significa que no hay una relación clara entre las variables. Es decir, los cambios en la inversión no se asocian de manera consistente con cambios en ventas. Por ejemplo, newspaper muestra correlaciones bajas con sales, lo que indica poca relación.

Comparación entre Pearson y Spearman. ¿Son relaciones estrictamente lineales?

Los valores de Pearson y Spearman son muy similares, lo que indica que la relación no solo es monótonica, sino también aproximadamente lineal. Si hubiera diferencias grandes entre ambos coeficientes, podría indicar una relación no lineal. Además, la nube de puntos (especialmente en TV vs ventas) muestra una tendencia creciente relativamente recta, lo que respalda que la relación es principalmente lineal, aunque no perfectamente exacta.

Fase 2: Regresión Lineal y Diagnóstico

Coeficiente	Valor
Intercepto (beta_0)	2,9389
Pendiente (beta_1)	0,0458
Pendiente (beta_2)	0,1885
Pendiente (beta_3)	- 0,0010

Tabla [2]: La tabla muestra los valores estimados del modelo de regresión, incluyendo el intercepto y el efecto de cada medio publicitario sobre las ventas.

Interpretación de Parámetros:

Intercepto (2,9389):

Si no se invierte en ningún medio, las ventas estimadas serían 2,94 unidades. Es el nivel base del modelo.

TV (0,0458):

Por cada unidad adicional invertida en TV, las ventas aumentan en 0,0458 unidades, manteniendo constantes las demás variables.

Radio (0,1885):

Por cada unidad adicional invertida en radio, las ventas aumentan en 0,1885 unidades. Es el efecto más fuerte del modelo.

Newspaper (-0,0010):

El efecto es prácticamente cero y ligeramente negativo, lo que indica que no tiene impacto relevante en las ventas cuando se consideran las otras variables.

Análisis de Bondad de Ajuste

TV ($R^2 = 0,612$)

Relación entre la inversión en publicidad en televisión y las ventas. La línea roja representa la recta de regresión lineal estimada. El coeficiente de determinación ($R^2 = 0.612$) indica que el 61.2% de la variabilidad en las ventas es explicada por la inversión en publicidad en TV.




Figura [4]: La figura muestra la regresión lineal simple entre la inversión en TV y las ventas, evidenciando un bajo alto de explicación del modelo ($R^2 = 0.612$).

Radio ($R^2 = 0.332$)

El modelo explica 33,2% de la variabilidad de las ventas. Es un nivel moderado de explicación; la inversión en radio tiene una relación importante con las ventas, aunque no las explica completamente.




Figura [5]: La figura presenta la regresión lineal simple entre la inversión en radio y las ventas, mostrando un nivel moderado de explicación ($R^2 = 0,332$)

Newspaper ($R^2 = 0.052$)

El modelo explica sólo 5.2% de la variabilidad de las ventas. Es un poder explicativo muy bajo, lo que indica que la inversión en newspaper casi no explica el comportamiento de las ventas.




Figura [6]: La figura muestra la regresión lineal simple entre la inversión en newspaper y las ventas, indicando un bajo nivel de explicación del modelo ($R^2 = 0.052$).

Estimación Matricial

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

► Calcular la matriz transpuesta x' .

$$x^T = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

► Calcule el producto $x'y$ y su respectiva matriz inversa $(x'x)^{-1}$

$$\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$$

matriz 2×5

matriz 5×2

Resultado matriz 2×2

$$\cdot \left(\frac{\text{adj } A}{\det A} \right)^T$$

$$\det A = 5 \times 55 - 15 \times 15 = 50$$

Producto $x'y$

$$A = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

$$\text{Adj } A \left[\begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \right]^T = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$A^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$A^{-1} = \begin{pmatrix} 55/50 & -15/50 \\ -15/50 & 5/50 \end{pmatrix}$$

matriz inversa $(x'x)^{-1} \rightarrow A^{-1} = \begin{pmatrix} 1,1 & -0,3 \\ -0,3 & 0,1 \end{pmatrix}$

$$A^{-1} = \begin{pmatrix} \frac{11}{10} & -\frac{3}{10} \\ -\frac{3}{10} & \frac{1}{10} \end{pmatrix}$$

► Calcule el producto $x'y$

$$\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} = \begin{pmatrix} 28 \\ 101 \end{pmatrix} \quad \text{Resultado}$$

$$1(2) + 1(4) + 1(6) + 1(7) + 1(9) = 28$$

$$1(2) + 2(4) + 3(6) + 4(7) + 5(9) = 101$$

► Obtenga el vector de parámetros β^1 y escriba la ecuación estimada de la recta $\hat{y} = \beta_0 + \beta_1 x$.

$$\begin{pmatrix} \frac{11}{10} & -\frac{3}{10} \\ -\frac{3}{10} & \frac{1}{10} \end{pmatrix} \cdot \begin{pmatrix} 28 \\ 101 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ \frac{17}{10} \end{pmatrix} \rightarrow \beta_0$$
$$\begin{pmatrix} \frac{1}{2} \\ \frac{17}{10} \end{pmatrix} \rightarrow \beta_1$$

$$\frac{11}{10} (28) + \left(-\frac{3}{10}\right) (101) = \frac{1}{2}$$

$$-\frac{3}{10} (28) + \frac{1}{10} (101) = \frac{17}{10}$$

ecuación $\hat{y} = 0,5 + 1,7x$

Árboles de Decisión y Comparación de Modelos

De acuerdo con la estructura del árbol, las particiones de los nodos se realizan bajo un criterio estadístico claro: reducir la variabilidad de las ventas dentro de cada grupo.

El modelo evalúa diferentes variables (TV y Newspaper) y distintos puntos de corte (por ejemplo, $TV \leq 122.05$) y selecciona aquel que minimiza el error cuadrático (squared_error). Esto significa que busca que las ventas dentro de cada nodo sean lo más similares posible entre sí.

El primer corte se hace con TV, porque es la variable que más reduce la variación total de las ventas en el conjunto completo de datos. Luego, en cada subconjunto, el árbol vuelve a dividir usando la variable que genere la mayor reducción adicional del error.




Figura [7]: La figura muestra la estructura del árbol de regresión para predecir las ventas a partir de TV y Newspaper, donde cada división se realiza buscando reducir la variabilidad interna y formar grupos con niveles de ventas más homogéneos.

Tarea:

①

► Calcule la entropía del Nodo Padre:

$$H(s) = - \sum p_i \log_2(p_i)$$

Altos $\rightarrow 3$

Bajos $\rightarrow 1$

$$H(s) = - \left[\frac{3}{4} \log_2 \frac{3}{4} + \frac{1}{4} \log_2 \frac{1}{4} \right]$$

$$H(s) = 0,8112$$

②

$$Gini = 1 - \left(\frac{3}{4}^2 + \frac{1}{4}^2 \right)$$

$$Gini = 1 - (0,562 + 0,062)$$

$$Gini = 0,376$$

El valor 0,376 indica que hay cierta mezcla en las clases, pero no es completamente aleatorio.

Conclusiones:

Tras completar el análisis exploratorio y el modelamiento matricial, se presentan las siguientes conclusiones:

1. Se concluye que la TV es el motor principal de ventas, mostrando la correlación más alta y una distribución de datos más equilibrada y predecible (sesgo de -0.07). Por el contrario, el Periódico (Newspaper) no solo tiene la asociación más débil, sino que presenta una asimetría positiva (0.89) que indica inversiones esporádicas de alto costo que no se traducen proporcionalmente en éxito comercial.
2. Interpretación de la Capacidad Predictiva: El modelo de regresión lineal múltiple permite establecer que el Radio tiene el coeficiente de pendiente más alto en términos unitarios, lo que sugiere que, aunque se invierte menos en total que en TV, cada dólar invertido en Radio genera un incremento marginal de ventas muy significativo bajo el principio de ceteris paribus.
3. Validación de la Estructura Lineal: La comparación entre los coeficientes de Pearson y Spearman en la Fase 1 confirmó que las relaciones son predominantemente lineales, lo que valida el uso de la aproximación matricial realizada en la Fase 2 para obtener estimadores confiables.
4. Limitaciones y Hallazgos Base: Se identificó un nivel de ventas base cercano a las 2,940 unidades, lo que representa el volumen de ventas que el mercado mantiene de forma orgánica sin el estímulo de los tres medios analizados. Esto subraya la importancia de la publicidad para escalar el negocio más allá de su punto de equilibrio natural.