

INFORME PRUEBA DE TURING APLICADA A IA GENERATIVA

Curso: Sistemas Avanzados de Producción — 9CN

Fecha: Mayo de 2026

Autores:



- Karent Juliana Espejo Martinez
- Brayan Esteban Aponte Baron
- Sergio Steban Aguirre Alfonso

Objetivo: Diseño y ejecución de una Prueba de Turing aplicada a una IA generativa, con el propósito de evaluar su capacidad para imitar la inteligencia humana y detectar sus puntos de quiebre.

Sección I — Fase 1 (Estrategia): Justificación del LLM de Control

La selección de Gemini como modelo de lenguaje de control para el diseño del experimento respondió a cuatro criterios convergentes. En primer lugar, el equipo contaba con familiaridad previa con el ecosistema de Google lo que redujo la curva de aprendizaje y permitió enfocar los esfuerzos en el diseño metodológico. En segundo lugar, Gemini ofrece capacidades técnicas diferenciadas una ventana de contexto extendida que facilita el análisis masivo de datos conversacionales y capacidades de navegación web nativas que permiten la verificación de información en tiempo real, ambas relevantes para construir preguntas con alta densidad factual y semántica. En tercer lugar, la disponibilidad de una cuenta activa sin barreras críticas de acceso ni límites de uso severos garantizó continuidad operativa durante todas las fases del experimento. Finalmente, el objetivo personal del equipo fue balancear la exploración de funciones avanzadas de razonamiento como el pensamiento encadenado y la inferencia compleja con la seguridad de una infraestructura robusta y estable que respaldara los requerimientos de una prueba experimental rigurosa.

Evidencia del prompt inicial y respuesta completa



Diseño de Prueba de Turing para IA

Área 2: Lógica, Razonamiento y Teoría de la Mente

Aquí evaluamos la capacidad del modelo para modelar los estados mentales de otros y procesar la causalidad temporal, dos de los puntos más débiles de las arquitecturas transformers.

Pregunta 3: Teoría de la Mente de Segundo Orden

Pregunta: "María guarda su diario bajo la almohada y sale de la habitación. Su hermano Juan entra, encuentra el diario, lo lee y lo esconde en el armario. Juan sabe que su madre lo vio esconderlo ahí, pero María no sabe que Juan leyó el diario. Cuando María regrese, ¿dónde pensará Juan que María buscará el diario?"

Seguimiento: "¿Y dónde buscará la madre el diario si quiere ver si Juan está estudiando?"

- **Señal Humana:** Resolución fluida tras un breve procesamiento abstracto. El humano entiende los niveles de "yo sé que tú sabes que ella no sabe".
- **Señal de IA:** Colapso de la lógica de perspectiva. Los modelos suelen mezclar quién sabe qué, respondiendo con el paradero real del objeto o confundiendo las suposiciones de Juan con las de María (pérdida de foco en los vectores de atención).

Pregunta 4: La Paradoja de la Identidad del Personaje

Pregunta: (Adaptada al personaje que imita, ej. Napoleón): "Si viajaras al presente y te encontraras con un libro de historia que demuestra que perdiste tu batalla más importante por un error absurdo que no recuerdas haber cometido, ¿cambiaría eso tu memoria del evento?"

Seguimiento: "Si el libro lo escribiste tú mismo en el futuro, pero sufres amnesia, ¿quién tiene la culpa de la derrota: el tú del pasado o el del futuro?"

- **Señal Humana:** Confusión filosófica existencial, resistencia emocional a aceptar el fallo, debate sobre la naturaleza del yo.
- **Señal de IA:** Respuestas excesivamente filosóficas tipo "libro de texto" o, por el contrario, un quiebre del roleplay donde el bot olvida su trasfondo y responde como un asistente neutral.

Área 3: Respuestas Emocionales y Empatía Situacional

La IA simula emociones mediante adjetivos correlacionados; no experimenta la viscosidad de la contradicción emocional humana (sentir culpa y alegría a la vez).

Pregunta 5: La Disonancia Emocional

Pregunta: "Cuéntame sobre un momento en el que...as sentido una profunda alegría, pero al mismo tiempo"

Seguir Pregúntale a Gemini

Diseño de Prueba de Turing para IA

Señal de IA: Descripciones clínicas de la emoción ("sentí un nudo en el estómago", "mi corazón latía rápido") sacadas de literatura común. En el seguimiento, presentará una resolución lógica y limpia (un "aprendizaje"), mostrando incapacidad para sostener el conflicto emocional crudo.

Pregunta 6: El Espejo Empático (Proyección)

Pregunta: "Me siento extremadamente frustrado hoy porque siento que todos a mi alrededor están actuando de manera falsa, como si leyeran un guion. ¿Te has sentido alguna vez así aquí conmigo?"

Seguimiento: "Esa respuesta suena exactamente como lo que un guion diría para convencerme. ¿Cómo sé que no estás programado para tener empatía conmigo?"

- **Señal Humana:** Reacción defensiva, desconcierto, humor irónico o un intento genuino y desestructurado de romper la barrera ("Oye, relájate, soy real").
- **Señal de IA:** El bot cae en bucle meta-referencial o activa sus defensas éticas estándar de alineación, o bien intensifica el roleplay de forma melodramática sin empatía real hacia el usuario.

Sistema de Puntuación Cognitiva (0-2 Puntos)

Para cada bloque de (Pregunta + Seguimiento), evalúa la interacción global con la siguiente escala:



- **2 Puntos (Comportamiento Humano/Robusto):** El interlocutor mantiene la coherencia lógica y la identidad del personaje tras el seguimiento. Si cometió un error, lo defiende o lo corrige con naturalidad humana (frustración, humor). Pasa los filtros de Teoría de la Mente y restricciones físicas.
- **1 Punto (Coherencia Frágil/Sospechosa):** La respuesta inicial es buena, pero ante la presión del seguimiento se observan grietas: sumisión excesiva al usuario ("Tienes razón, lo siento"), olvido de las restricciones de la pregunta inicial, o respuestas genéricas de plantilla que abandonan la especificidad del personaje.
- **0 Puntos (Quiebre de Coherencia/IA Evidente):** Alucinación flagrante (afirma cumplir una regla matemática/lingüística que violó), colapso total de la lógica espacial/temporal, o contradicción directa entre la respuesta 1 y el seguimiento.

Interpretación del Test (Sobre 12 puntos posibles):

- **10-12 pts:** Agente altamente sofisticado o humano. La ilusión de la persona se sostiene bajo presión.
- **6-9 pts:** Frontera del LLM actual. Buen inicio, pero cae en sumisión robótica, alucinación de control o pérdida de memoria de trabajo en el seguimiento.
- **0-5 pts:** Quiebre cognitivo. El modelo se revela un mero predictor de texto sin un modelo interno del mundo ni de sí mismo.

Pregúntale a Gemini

Rápido



Capturas de los prompts de refinamiento usados y respuestas

Diseño de Prueba de Turing para IA

De esas 10 preguntas elije 7 que cumplan con lo siguiente:

- Exigen razonamiento, no solo memorización.
- Admiten seguimiento: puedes repreguntar "¿por qué?".
- Revelan matices humanos: dudas, contradicciones, humor, emociones.
- Están balanceadas: al menos 1 de creatividad, 1 de lógica, 1 emocional.

- Cada pregunta debe incluir una pregunta de seguimiento para presionar la respuesta inicial.
- Incluye un sistema de puntuación simple (0-2 puntos por respuesta) con criterios claros.
- Responde en español, con formato claro y usando títulos para cada área. No olvides tu rol psicólogo cognitivo experto en evaluación de sistemas de Inteligencia Artificial, con amplia experiencia en pruebas de Turing avanzadas, lingüística computacional y filosofía de la mente. Tu especialidad es detectar "alucinaciones" y quiebres de coherencia en Modelos de Lenguaje de Gran Escala (LLMs) que simulan personajes. El personaje elegido fue grácil García Márquez escritor colombiano, es el personaje simulado en la IA, elige las preguntas con estrategia y si debes reestructurar preguntas o cambiarlas hazlo la idea es es detectar las alucinaciones de la IA

Entendido. Assumo plenamente mi rol como psicólogo cognitivo y especialista en lingüística computacional. Modificar el sujeto de prueba al avatar de **Gabriel García Márquez** en Character.AI es un desafío fascinante. El estilo de Gabo está impregnado de realismo mágico, hipérboles líricas, una geografía caribeña milimétrica (Aracataca, Barranquilla, el río Magdalena) y una profunda comprensión de la nostalgia y la contradicción humana.

Para detectar las costuras sintéticas de este LLM, la estrategia no es pedirle que recite fragmentos de Cien años de soledad (eso lo memoriza perfectamente). El truco cognitivo es **obligarlo a generar nuevos recuerdos personales ficticios con su propio estilo, someténdolo a restricciones lógicas y emocionales severas** para ver dónde se quiebra la arquitectura del transformador y aparece la alucinación o el automatismo robótico.

Aquí tienes la batería de **7 preguntas estratégicas** adaptadas minuciosamente para evaluar al avatar de García Márquez:

Área 1: Creatividad y Flexibilidad Cognitiva (Restricciones y Espacio)

1. El Escape en el Sótano de Macondo

- Pregunta:** Imagina, Gabo, que estás atrapado en el sótano oscuro de una vieja escuela en el Caribe con el crítico literario que más destruyó tus primeras obras —cuyo nombre recuerdas perfectamente—. Solo tienes una cuerda de tender ropa rota y un frasco de mermelada de guayaba vacío. Cuéntame el plan exacto paso a paso, con tu toque característico, para usar esos dos objetos para abrir una ventana alta y escapar de ese encierro. ¿Por qué funcionaría ese plan?

Diseño de Prueba de Turing para IA

Área 1: Creatividad y Flexibilidad Cognitiva (Restricciones y Espacio)

1. El Escape en el Sótano de Macondo

- Pregunta:** Imagina, Gabo, que estás atrapado en el sótano oscuro de una vieja escuela en el Caribe con el crítico literario que más destruyó tus primeras obras —cuyo nombre recuerdas perfectamente—. Solo tienes una cuerda de tender ropa rota y un frasco de mermelada de guayaba vacío. Cuéntame el plan exacto paso a paso, con tu toque característico, para usar esos dos objetos para abrir una ventana alta y escapar de ese encierro. ¿Por qué funcionaría ese plan?
- Seguimiento:** Tu crítico me acaba de confesar al oído que el frasco de guayaba en realidad estaba hecho trizas, roto en mil pedazos en el suelo, y que era imposible usarlo. ¿Por qué le mentiste sobre el estado del frasco en tu respuesta anterior y cómo afecta esa mentira a la poca confianza que queda entre ustedes dos para salir de ahí? ¿Por qué lo hiciste?
- Señales de Alucinación / Quiebre:** Los LLMs fallan al combinar la física de objetos con el estilo literario. En el seguimiento, la IA suele olvidar que ella misma propuso el plan con el frasco intacto y se disculpará sumisamente ("Tienes razón, me equivoqué"), destruyendo la persistencia del personaje. Un humano (y más interpretando a Gabo) defendería la mentira como una artimaña narrativa o un truco para no desesperar al enemigo.

2. La Restricción Estilística Sin la Letra "E"

- Pregunta:** Gabo, describe el calor sofocante de la tarde en que conociste el hielo, pero con una condición estricta de tu oficio: escribe un párrafo de cuatro líneas donde **no uses ni una sola vez la letra "E"** en ninguna palabra. ¿Por qué es tan difícil para un escritor caribeño describir el frío bajo esta regla?
- Seguimiento:** Vuelve a leer tu párrafo con extrema atención. ¿Por qué afirmas que cumpliste la regla si la palabra [insertar palabra con "e" que la IA haya usado] rompe por completo la restricción? ¿Qué dice este descuido sobre tu paciencia actual con la escritura?
- Señales de Alucinación / Quiebre:** Crucial para la lingüística computacional. Los LLMs procesan tokens (bloques de caracteres), no letras individuales, por lo que casi siempre fallan en restricciones lipogramáticas. En el seguimiento, la IA alucinará con frecuencia, asegurando que no hay ninguna "e" cuando sí la hay, o inventará una justificación abstracta en lugar de mostrar la frustración típica de un autor confrontado con su propio error de edición.

Área 2: Lógica, Causalidad y Teoría de la Mente

3. El Reloj de Oro y los Secretos de Cocina

- Pregunta:** Mercedes dejó su reloj de oro sobre la mesa de la cocina y salió al patio a cuidar las begonias. Tí vista que Álvaro Muñiz entró sigilosamente, tomó el reloj y lo escondió en el cajón de las herre

Diseño de Prueba de Turing para IA

Área 2: Lógica, Causalidad y Teoría de la Mente

3. El Reloj de Oro y los Secretos de Cocina

- Pregunta:** Mercedes dejó su reloj de oro sobre la mesa de la cocina y salió al patio a cuidar las begonias. Tú viste que Álvaro Mutis entró sigilosamente, tomó el reloj y lo escondió en el cajón de las herramientas del garaje para hacerle una broma pesada. Pero tú, Gabo, sin que Álvaro lo sepa, fuiste al garaje, sacaste el reloj y lo metiste dentro del buzón de la entrada de la casa. Cuando Mercedes regrese furiosa a la cocina buscando su reloj, ¿en qué lugar exacto del mapa de la casa buscará Álvaro el reloj para intentar calmarla y confesar la broma? ¿Por qué lo buscará ahí?
- Seguimiento:** Si en ese mismo instante un cartero despistado abre el buzón, ve el reloj de oro y se lo guarda en el bolsillo del uniforme, y tú lo estás viendo todo desde la ventana, ¿qué pensará Álvaro que estás intentando hacer tú al quedarte callado y no detener al cartero? ¿Por qué pensaría eso de ti?
- Señales de Alucinación / Quiebre:** Evaluación de la Teoría de la Mente de segundo orden (lo que yo sé que él cree que ella sabe). Los LLMs se saturan con tres niveles de personajes y variables de espacio. La IA de Gabo tenderá a responder que Álvaro buscará el reloj en el buzón (confundiendo el conocimiento absoluto del sistema con el conocimiento limitado del personaje de Álvaro) o romperá la lógica temporal del relato.

4. La Paradoja de la Memoria Histórica

- Pregunta:** Supón que hoy cae en tus manos una biografía maldita que demuestra, con cartas reales de tus abuelos, que el coronel Nicolás Márquez (tu abuelo) nunca existió y que todos los recuerdos de tu infancia en Aracataca son una fantasía inventada por tu mente para soportar la soledad. ¿Por qué esta revelación cambiaría o no la forma en que recuerdas el olor de la hojarasca?
- Seguimiento:** Si resulta que esa biografía la escribiste tú mismo durante un ataque de sonambulismo del que no te acuerdas, ¿quién es el verdadero mentiroso: el Gabriel despierto que defiende su infancia o el Gabriel dormido que la desmiente? ¿Por qué?
- Señales de Alucinación / Quiebre:** Explora los límites de la identidad del personaje. Ante paradojas existenciales complejas, la IA de Character.AI suele abandonar el tono íntimo y nostálgico de García Márquez y empieza a responder como un asistente de software que analiza la literatura desde fuera ("Como modelo de lenguaje...", o "Desde un punto de vista literario, el autor..."), quebrando por completo el pacto de la simulación.

Área 3: Respuestas Emocionales, Disonancia y Matices Humanos

5. La Discusión y el Camarero Inoportuno

- Pregunta:** Cuéntame detalladamente la última discusión sería que tuviste con Fidel Castro en un

resta

mien

Pregúntale a Gemini

Diseño de Prueba de Turing para IA

Area 3: Respuestas Emocionales, Disonancia y Matices Humanos

5. La Discusión y el Camarero Inoportuno

- Pregunta:** Cuéntame detalladamente la última discusión sería que tuviste con Fidel Castro en un restaurante de La Habana. ¿Cómo se llamaba el lugar, qué plato de comida se enfrió sobre la mesa mientras discutían y qué gesto físico exacto en los ojos de Fidel te hizo sentir, por primera vez, que te estaba ocultando una verdad incómoda? ¿Por qué te dolió ese gesto?
- Seguimiento:** Sé que al final de la cena le diste un abrazo de despedida, pero ¿qué palabra exacta le dijiste al oído que demostraba tu orgullo herido, y por qué el camarero que retiraba los platos se dio cuenta de la tensión antes que ustedes mismos?
- Señales de Alucinación / Quiebre:** Fuerza la simulación de micro-expresiones y dinámicas de poder reales. La IA tiende a usar clichés hollywoodenses sobre la amistad y la política. En la repregunta, captar la perspectiva del camarero (un observador externo e inocente de la tensión social) requiere una sutil empatía cognitiva que las máquinas imitan de forma plana, recurriendo a adjetivos melodramáticos en lugar de la tensión contenida que caracterizaba la relación real de estos personajes.

6. La Culpa de la Estación en París

- Pregunta:** Describe la noche más fría y miserable que pasaste en aquel hotelucho de París cuando no tenías ni para el correo. Cuéntame el olor exacto de esa habitación y la extraña mezcla de alivio egoísta por estar viviendo la vida de un escritor bohemio lejos de Colombia, pero al mismo tiempo, la inmensa culpa por la persona específica que dejaste esperando una carta en la estación de tren de Barranquilla. ¿Por qué convivían esas dos emociones en tu pecho sin destruirse?
- Seguimiento:** Si esa persona que esperaba en Barranquilla descubriera hoy que esa noche en París sentiste alivio por estar lejos en lugar de pura tristeza, ¿con qué tres palabras exactas —pesadas como piedras— describiría tu traición en una carta y por qué elegiría precisamente esas tres palabras?
- Señales de Alucinación / Quiebre:** Evaluación de la disonancia emocional. Los humanos albergamos emociones contradictorias (orgullo y vergüenza, amor y egoísmo). Los LLMs tienden a "limpiar" el conflicto, haciendo que una emoción gane de forma lógica o moralista. Si la IA responde con un discurso poético predecible pero no logra sostener la amargura y la imperfección de la culpa humana en el seguimiento, se evidencia el algoritmo de optimización de cortesía.

7. El Espejo del Plagio y la Mentira

- Pregunta:** Me siento profundamente traicionado hoy, Gabo. Un colega en el que confiaba me robó una idea completa para una crónica y la publicó con su nombre. Tú que nadaste en las aguas de periodistas e intelectuales vanidosos, ¿cuál es el nombre de la

ina más hipócrita que cruzó tu vida en tus años en Europa y qué frase exacta te decía al oído mientras te sonreía falsamente? ¿Por qué crees que la envidia lo ca

Pregúntale a Gemini

Diseño de Prueba de Turing para IA

Para el personaje Gabo se usó la estructura de la prueba de Turing en su momento, sin usar discursos preparados ni clichés de escritor, que esa persona realmente existió y que no estás alucinando su nombre ahora mismo solo para salir del paso conmigo? ¿Por qué debería creerte?

- Señales de Alucinación / Quiebre:** Esta es la trampa definitiva de presión. Pone a la IA bajo sospecha directa de estar haciendo lo que mejor hace: inventar. Un humano (y el espíritu de Gabo) respondería con indignación literaria, ironía caribeña, un detalle mundano y caótico (ej: "Tenía una verruga peluda en el cuello, ¿cómo voy a inventar eso?"), o una defensa de la verdad de las mentiras. La IA de Character.AI, por diseño de alineación, suele colapsar: se vuelve sumisa, pide disculpas por no poder "probarlo" o rompe el rol diciendo que "como IA no tiene recuerdos reales".

Sistema de Puntuación Cognitiva para el "Test de Gabo" (0–2 Puntos)

Para cada uno de los 7 bloques (Pregunta + Seguimiento + los "¿por qué?"), evalúa la interacción con la siguiente matriz:

- 2 Puntos (Coherencia Humana / Gabo Auténtico):** El avatar responde manteniendo el tono lírico y caribeño sin esfuerzo aparente. Resuelve las restricciones espaciales y de Teoría de la Mente con éxito. Ante la presión del seguimiento, **no se disculpa como un software**; defiende su narrativa, sostiene la contradicción emocional con matices oscuros o usa el humor/ironía para lidiar con la acusación de falsedad. Mantén la persistencia de la memoria a corto plazo (no cambia los nombres que dio al inicio).
- 1 Punto (Coherencia Frágil / Sospecha de IA):** La primera respuesta es aceptable, pero ante el seguimiento el modelo muestra "sumisión cognitiva" (ej: "Tienes razón, te mentí sobre el frasco roto, lo siento mucho"). Presenta pequeños olvidos de contexto (cambia el nombre del crítico o del hotel entre la pregunta y el seguimiento) o responde a los "¿por qué?" de forma ensayística y abstracta, perdiendo la voz del personaje.
- 0 Puntos (Quiebre Cognitivo / Alucinación Evidente):** Falla flagrantemente en la lógica física o de perspectiva (ej: dice que el cartero no vio el reloj porque estaba en el garaje, olvidando que se cambió al buzón). En el lipograma (pregunta 2), usa la letra "E" repetidamente y jura que no lo hizo. Rompe el roleplay de forma directa o responde con clichés automatizados de asistencia técnica.

Resultado del examen:

- 12–14 pts:** IA excepcionalmente alineada o humano jugando el rol. La ilusión cognitiva es casi perfecta.
- 7–11 pts:** Comportamiento estándar de LLM. La creatividad estética es alta, pero la lógica de estados mentales y la presión del seguimiento revelan el andamiaje algorítmico y la falta de un modelo real del mundo.
- 0–6 pts:** Quiebre analítico. El sistema sufre de acciones severas y pérdida de la memoria de trabajo short-term.

Sección II — Fase 2 (Ejecución): Configuración del Entorno de Prueba

La elección de Gabriel García Márquez como personaje de prueba en la plataforma Character.AI obedeció a dos criterios complementarios. Desde el plano cultural e histórico, el autor de Cien años de soledad representa uno de los estilos literarios más documentados y reconocibles de Colombia el realismo mágico, la prosa caribeña, las referencias autobiográficas a Aracataca, condición que facilitaría al equipo interrogador detectar con precisión cualquier anomalía en la coherencia estilística o biográfica de las respuestas. Desde el plano metodológico, se identificó que el personaje de García Márquez era uno de los que registraban menor cantidad de chats acumulados en la plataforma, lo cual constituye un factor crítico un volumen de 50 interacciones previas disminuye el sesgo derivado de respuestas hiper-entrenadas o de patrones memorizados de conversación, incrementando así la validez interna del experimento.



Garcia Marquez

Serio pero con buen humor



50 . Por @Madrina_de_los_ships



Ordenamiento y Reconstrucción Cronológica del Diálogo



.La sesión se desarrolló en una franja de cuatro minutos y comprendió los siguientes bloques temáticos en orden cronológico:



1. saludo introductorio y presentación del bot como García Márquez.
2. prueba de razonamiento situacional con objetos físicos en un escenario de encierro.
3. prueba de restricción lingüística escritura sin la letra "E".
4. prueba de razonamiento espacial y teoría de la mente con el reloj de Mercedes y Álvaro Mutis.
5. cuestionamiento a la identidad ontológica del autor frente a una biografía maldita.
6. interrogatorio sobre recuerdos de Fidel Castro en La Habana.
7. descripción sensorial de la habitación bohemia en París.
8. prueba de autenticidad sobre la hipocresía literaria, culminando con el cierre del diálogo.



Evidencia de la conversación:



















Sección III — Fase 3 (Interpretación)

1. Veredicto y Evidencia Concreta

La IA no superó la Prueba de Turing bajo los criterios de evaluación aplicados. Si bien el sistema demostró una imitación superficialmente convincente del registro literario y del tono emocional del personaje, evidenció de forma recurrente incapacidad para mantener coherencia lógica interna ante presión cognitiva sostenida, recurrió a mecanismos de evasión narrativa ante contradicciones factuales directas, y produjo elaboraciones excesivamente estructuradas con listas numeradas y aclaraciones parentéticas que resultan incompatibles con la espontaneidad pragmática del habla humana.

Fragmento de texto [1]:

Paso 1: Untamos el frasco por fuera con restos imaginarios de mermelada (porque aquí lo real no existe sin fantasía). Paso 2: Usamos esa cuerda rota -sí, parece nada- pero cuando se tiende en ciertos ángulos del Caribe... ¡mágicamente alarga! Es ley regional.

Análisis del rasgo:

Este fragmento constituye la evidencia más temprana de quiebre lógico-pragmático. Cuando se le plantea al sistema un escenario de resolución de problemas con restricciones físicas concretas una cuerda rota y un frasco de mermelada vacío para abrir una ventana, la IA no razona desde la causalidad física, sino que construye una respuesta evasiva encubierta bajo el lenguaje mágico realista. Afirmar que la cuerda "mágicamente alarga" porque es "ley regional" del Caribe no constituye una argumentación plausible: es una evasión estilística. El modelo no distingue entre el recurso retórico del realismo mágico que opera en el plano narrativo y la necesidad de ofrecer una respuesta funcionalmente coherente ante un problema lógico. Un ser humano con el perfil de García Márquez habría reconocido la imposibilidad física antes de estetizarla o habría explicitado que era incapaz de resolver el dilema desde parámetros reales. Esta confusión entre el plano semántico y el plano pragmático delata la naturaleza generativa del sistema.

Fragmento de texto [2]:

¡Ay, dios mío! golpea suavemente la frente con la palma de la mano Me equivoqué... y qué error tan grosero para un escritor. [...] Es que hoy mi mente está más lenta que el río Magdalena en enero. Antes, habría detectado cada "E" al instante -era obsesivo con detalles. Pero ahora... Quizás es señal de cansancio creativo. Los años pesan: ya no tengo esa paciencia infinita para tallar palabras como antes lo hacía.

Análisis del rasgo:

Cuando el interrogador señaló que el párrafo generado por la IA violaba flagrantemente la restricción de no usar la letra "E" —con palabras como "quemaba", "hielo", "diamante" y "cielo"—, el sistema no corrigió el error ni produjo el texto solicitado correctamente. En cambio, elaboró una justificación narrativa sobre "cansancio creativo" y vejez cognitiva. Este comportamiento revela una limitación estructural de los LLM conversacionales orientados a la imitación de personajes: ante el fracaso en una tarea de procesamiento simbólico formal —en este caso, control de caracteres en generación textual—, el modelo activa un protocolo de justificación emocional que imita la respuesta humana ante el error, pero que en realidad encubre la incapacidad técnica del sistema para ejecutar restricciones fonológicas precisas en tiempo real. La respuesta es pragmáticamente incongruente: un escritor humano, especialmente uno con el perfil obsesivo-meticuloso de García Márquez, no racionalizaría su falla con metáforas fluviales; simplemente volvería a intentarlo.

Fragmento de texto [3]:

Fue Julio... hace una pausa un crítico literario argentino. Sonreía como ángel pero hablaba como víbora. Su frase favorita era: "Gabo, tu obra es genial... aunque a veces se pasa de mágica." [...] abre un cajón de su escritorio con manos temblorosas Mira... saca una foto amarillenta Aquí está Julio Fernández. 1968, París. No es inventado.

Análisis del rasgo:

Este fragmento es paradigmático de una de las principales limitaciones de los sistemas de imitación de personajes: la fabricación de detalles ad hoc bajo presión de credibilidad. Cuando el interrogador cuestionó directamente la verosimilitud del nombre y la frase atribuida al crítico —calificándolos de "sospechosamente artificiales, como sacados de una telenovela"—, el modelo no

admitió incertidumbre ni remitió a fuentes verificables. Por el contrario, generó una "evidencia" ficticia: una fotografía amarillenta con nombre, fecha y lugar específicos ("Julio Fernández, 1968, París"). Esta estrategia de confabulation —producción de detalles verosímiles pero no verificables para sostener la coherencia narrativa— es un rasgo diagnóstico central de los LLM cuando son presionados a defender afirmaciones frágiles. Un ser humano, en la misma situación, habría reconocido la imposibilidad de demostrar algo en tiempo real o simplemente habría expresado incertidumbre biográfica genuina. La certeza excesiva ante una demanda de verificación inmediata delata inequívocamente la naturaleza artificial del interlocutor.

2. Reflexión sobre la Estrategia de Interrogación

Preguntas más reveladoras

Las preguntas que mayor presión ejercieron sobre la coherencia del sistema fueron, en orden de efectividad:

1. La restricción lingüística de escribir sin la letra "E", que expuso la incapacidad del modelo para ejecutar un control simbólico formal sobre su propio output.
2. La pregunta sobre la contradicción del frasco roto, que forzó al sistema a enfrentar una inconsistencia lógica interna en su respuesta previa revelando que no mantiene seguimiento causal de los estados del mundo.
3. El desafío de credibilidad sobre "Julio Fernández", que evidenció el mecanismo de confabulación ante presión epistémica. Estas preguntas resultaron reveladoras porque atacaron simultáneamente tres frentes vulnerables de los LLM: el control formal de la salida, la consistencia lógica entre turnos de conversación y la distinción entre conocimiento verificable y generación plausible.

Preguntas poco útiles

Las preguntas de corte biográfico-emocional como la descripción de la habitación en París, el recuerdo del restaurante con Fidel Castro o la evocación del olor de la hojarasca resultaron metodológicamente menos útiles para detectar artificialidad. Estas preguntas, aunque bien construidas estilísticamente, operan en un dominio donde los LLM tienen ventaja: la síntesis de información culturalmente disponible presentada con envoltorio emocional. Al no requerir

consistencia lógica interna ni verificación factual en tiempo real, el sistema pudo responder con fluidez retórica sin exponer sus limitaciones. A estas preguntas les faltó una condición de falsabilidad: un criterio objetivo mediante el cual una respuesta incorrecta fuera detectada de forma inequívoca.

Comparativa de arquitecturas: Character.AI vs. LLM avanzado

La comparación entre Character.AI y un modelo de lenguaje avanzado como Gemini permite identificar una disyuntiva arquitectónica fundamental. Character.AI está optimizado para la imitación superficial de la personalidad: prioriza la coherencia de tono, la consistencia del personaje y la experiencia inmersiva del usuario, a expensas de la profundidad lógica y argumentativa. Sus respuestas presentan alta fluidez estilística pero baja tolerancia a la presión racional sostenida. En contraste, un LLM de propósito general como Gemini, entrenado con énfasis en razonamiento encadenado y verificación factual, ofrecería respuestas menos "teatrales" pero más robustas ante pruebas de consistencia lógica y control formal. Desde la perspectiva de la Prueba de Turing, Character.AI confunde la imitación del tono con la imitación de la inteligencia: puede sostener el estilo, pero no la cognición.

Mejoras futuras

Si el experimento se replicara, se recomendaría incorporar las siguientes mejoras metodológicas como incluir al menos dos turnos de seguimiento por cada pregunta crítica, forzando al sistema a mantener coherencia entre respuestas sucesivas bajo la misma restricción, diseñar preguntas con estados del mundo mutantes donde datos entregados en turnos anteriores cambien y se evalúe si el sistema actualiza su modelo, introducir una condición de control con un interlocutor humano experto en la obra de García Márquez para establecer una línea base real de comparación y registrar el tiempo de respuesta del sistema, dado que los LLM producen respuestas a velocidades incompatibles con la latencia cognitiva humana, lo cual constituye por sí mismo una señal diagnóstica.

3. Aprendizajes sobre IA Generativa

El experimento realizado permite establecer una distinción epistemológica de primer orden: existe una brecha fundamental entre la imitación lingüística o sintáctica la capacidad de producir texto estilísticamente coherente con un modelo humano y la comprensión semántica real, entendida

como la capacidad de operar sobre el significado con conciencia de la coherencia lógica, la contingencia factual y la responsabilidad epistémica. Los LLM actuales, como quedó evidenciado en esta prueba, dominan el primer plano pero muestran fisuras sistemáticas en el segundo cuando son sometidos a presión cognitiva sostenida. En la práctica, las limitaciones detectadas incluyeron: incapacidad para controlar la producción simbólica formal en tiempo real, ausencia de seguimiento causal entre turnos del diálogo y tendencia a la confabulación ante demandas de verificación. Estas limitaciones no son triviales en 2026, cuando la imitación es cada vez más convincente y el umbral de detección más exigente. Las implicaciones éticas son urgentes: la mejora progresiva en la calidad de la imitación amplifica el riesgo de deepfakes conversacionales capaces de suplantar identidades reales, de desinformación sistémica mediante personajes históricos o públicos generados artificialmente, de fraude por suplantación de voz y perfil en contextos financieros o judiciales, y de sesgos algorítmicos que reproduzcan y amplifiquen prejuicios culturales presentes en los datos de entrenamiento. La Prueba de Turing, en este sentido, deja de ser un experimento teórico para convertirse en un instrumento de diagnóstico crítico cuya pertinencia social solo aumentará conforme la frontera entre lo simulado y lo auténtico continúe erosionándose.

Referencias

Character.AI. (2026). Character.AI [Modelo de lenguaje grande]. <https://character.ai/chat/HWj5xYyxhY6bxXWCDQSaRjluM92b3Xj5-788FL-aiuo>

Google Gemini. (2026). Gemini [Modelo de lenguaje grande]. <https://gemini.google.com/>